

# Spectral bandits for smooth graph functions

---

Tomáš Kocák

14. november 2018

# Multi-armed bandit problém



**Bandit 1**

Reward  $r_1$

$$\mu_1 = \mathbb{E}[r_1]$$



**Bandit 2**

Reward  $r_2$

$$\mu_2 = \mathbb{E}[r_2]$$

...



**Bandit  $N$**

Reward  $r_N$

$$\mu_N = \mathbb{E}[r_N]$$

**Sekvenčný problém** - v každom kole sa opakuje:

- **Vyber akciu** - jeden z  $N$  hracích automatov
- **Obdrž odmenu** - náhodná premenná s fixnou strednou hodnotou

**Cieľ:** maximalizovať celkový zisk (po  $T$  kolách)

# Multi-armed bandit problém - aplikácie

- **Klinické štúdie**

- Podat' pacientovi jeden z  $N$  liekov na chorobu.
- Pozorovať výsledok liečby (odmena)
- **Cieľ:** maximalizovať množstvo vyliečených pacientov

- **Odporúčacie systémy**

- Odporučiť užívateľovi film, pesničku, ...
- Obdržať hodnotenie filmu, pesničky, ...
- **Cieľ:** maximalizovať spokojnosť užívateľa

- **Cielená reklama**

- Zobrazit' užívateľovi jednu z  $N$  reklám
- Obdržať spätnú väzbu od užívateľa (klik)
- **Cieľ:** maximalizovať množstvo vyliečených pacientov

- **Rybárčenie**

- Na začiatku dňa si vybrať jedno z  $N$  miest
- Na konci dňa pozorovať množstvo ulovených rýb
- **Cieľ:** maximalizovať množstvo rýb po  $T$  dňoch

# Multi-armed bandit problém

## Špecifikácia problému

- $T$  – počet opakovaní
- $N$  – počet akcií
- $r_{t,i}$  – odmena akcie  $i$  v čase  $t$

## V každom kole:

- Algoritmus zvolí akciu  $I_t$
- Algoritmus obdrží odmenu  $r_{t,I_t}$
- Algoritmus si upraví preferencie

Cieľ po  $T$  kolách:

- **Maximalizovať celkovú odmenu**
- **Minimalizovať celkový očakávaný regret**

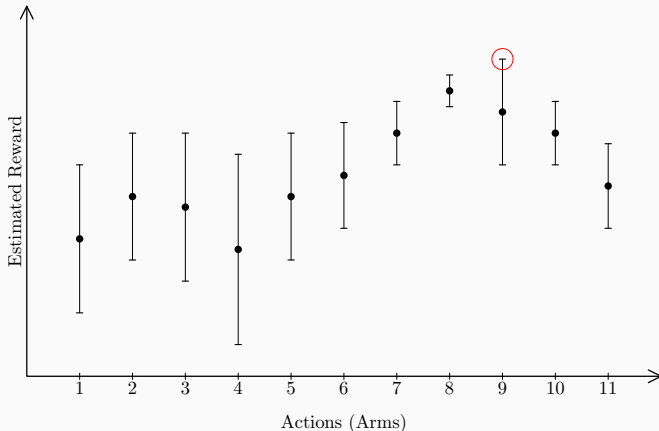
### Kumulatívny regret

$$R_T = \max_{j \in [N]} \mathbb{E} \left[ \sum_{t=1}^T r_{t,j} \right] - \mathbb{E} \left[ \sum_{t=1}^T r_{t,I_t} \right]$$

# Upper confidence bound algoritmus

**UCB algoritmus** - jeden z najznámejších algorithmov pre tento problém

- Zvoľme akciu s najvyššou hornou hranica intervalu spoľahlivosti
- Obdržme odmenu prislúchajúcu k zvolenej akcii
- Upravme interval spoľahlivosti



# Čo očakávame od regretu?

## Kumulatívny regret

$$R_T = \max_{j \in [N]} \mathbb{E} \left[ \sum_{t=1}^T r_{t,j} \right] - \mathbb{E} \left[ \sum_{t=1}^T r_{t,l_t} \right]$$

Náhodný algoritmus:

$$R_T = \mathcal{O}(T)$$

Vševediaci algoritmus:

$$R_T = \mathcal{O}(0)$$

**UCB algoritmus:**

Horný odhad na regret:

$$R_T = \tilde{\mathcal{O}}(\sqrt{NT})$$

Existujú ťažké problémy:

$$R_T = \Omega(\sqrt{NT})$$

# Odhady na regret

Horný odhad na regret:

$$R_T = \tilde{O}(\sqrt{NT})$$

Existujú ťažké problémy:

$$R_T = \Omega(\sqrt{NT})$$

## Dá sa odhad na regret vylepšiť?

- Vo všeobecnosti: **NIE!**
- S dodatočnými predpokladmi: **ÁNO!**

Očakávanie na odhad na regret (s využitím štruktúry problému):

$$R_T = \tilde{O}(\sqrt{DT})$$

- $D$  zachytáva štruktúru
- $D$  je menšie ako  $N$

Zvyčajný prístup: kontextuálni banditi

# Banditi s podobnosťami


---

## Spectrálni banditi



# Rybársky príklad

Spektrálna bandita:



# Hladkosť funkcie na grafe

Hladkosť funkcie  $r$  (vzhľadom na graf  $G$ )

$$S_G(\mathbf{r}) = \frac{1}{2} \sum_{i,j \in [N]} s_{i,j} (r_i - r_j)^2 = \mathbf{r}^\top \mathcal{L} \mathbf{r}$$

- $r_i$  – odmena akcie  $i$
- $\mathbf{r} = [r_1, r_2, \dots, r_N]^\top$  – vektor odmien (funkcia na grafe)
- $s_{i,j}$  – váha na hrane spájajúcej akcie  $i$  a  $j$
- $\mathcal{L}$  – Laplaceova matica grafu  $G$
- $S_G(\mathbf{r})$  – **hladkosť funkcie  $\mathbf{r}$  na grafe  $G$**

Funkcia  $\mathbf{r}$  je hladká

$\Leftrightarrow$

$S_G(\mathbf{r})$  je blízke nule

# Vlastnosti hladkých funkcí

$$S_G(\mathbf{r}) = \mathbf{r}^\top \mathcal{L} \mathbf{r} = \mathbf{r}^\top \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^\top \mathbf{r} = \boldsymbol{\alpha}^\top \mathbf{\Lambda} \boldsymbol{\alpha} = \|\boldsymbol{\alpha}\|_{\mathbf{\Lambda}} = \sum_{i=1}^N \lambda_i \alpha_i^2$$

- $\mathcal{L}$

Čo znamená "veľké"  $\lambda_i$ ?

Koľko koeficientov  $\alpha_i$  je podstatných?

$$\mathbf{r} = \begin{bmatrix} r_1 \\ r_2 \\ \vdots \\ r_N \end{bmatrix} = \begin{bmatrix} | \\ q_1 \\ | \end{bmatrix} \alpha_1 + \begin{bmatrix} | \\ q_2 \\ | \end{bmatrix} \alpha_2 + \cdots + \begin{bmatrix} | \\ q_N \\ | \end{bmatrix} \alpha_N = \mathbf{Q} \boldsymbol{\alpha}$$

Veľké  $\lambda_i$

$\Rightarrow$

malé  $\alpha_i$

## Effective dimension

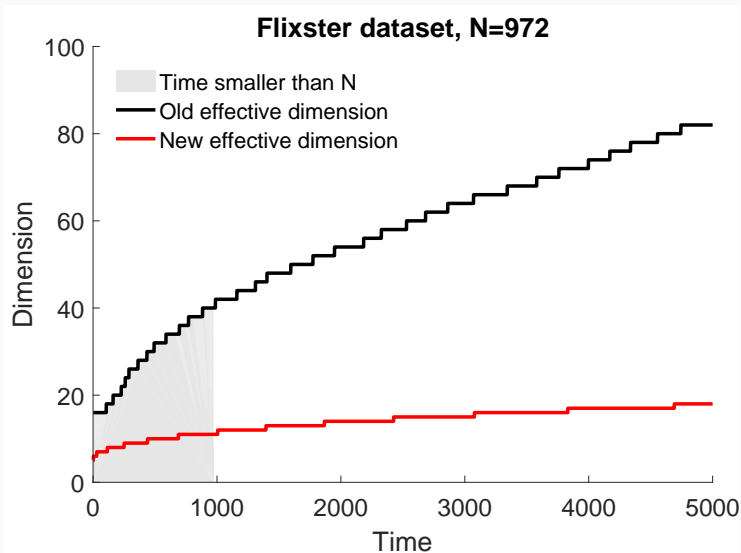
$$d = \left\lceil \frac{\max \log \prod_{i=1}^N \left(1 + \frac{t_i}{\lambda_i}\right)}{\log \left(1 + \frac{T}{K\lambda}\right)} \right\rceil$$

- $\{t_1, \dots, t_N\}$  sú nezáporné celé čísla také, že  $\sum_{i=1}^N t_i = T$ .
- $\lambda$  – regularizácia
- $K$  – počet komponentov grafu  $G$

### Vlastnosti effective dimension:

- Zvyčajne **oveľa menšia ako  $N$**
- **Závislá na čase:** veľké  $T \Rightarrow$  viac dimenzií je podstatných
-

## Effective dimension – Flixster dataset



# Algoritmus pre spektrálnych banditov

## SpectralUCB algoritmus:

### Inicializácia:

$$\hat{\alpha}_1 = 0_N$$

– počiatočný odhad na  $\alpha$

$$\mathbf{V}_1 = \Lambda_{\mathcal{L}} + \lambda \mathbf{I}$$

### V každom kole:

$$\hat{r}_i = \mathbf{x}_i^\top \hat{\alpha}$$

– odhad odmeny  $r_i$  akcie  $i$

$$I_t = \arg \max_a \left( \mathbf{x}_a^\top \hat{\alpha} + c \|\mathbf{x}_a\|_{\mathbf{V}_t^{-1}} \right)$$

– akcia ktorú vyberieme

$$\mathbf{V}_{t+1} = \mathbf{V}_t + \mathbf{x}_{I_t} \mathbf{x}_{I_t}^\top$$

$$\hat{\alpha}_{t+1} = \mathbf{V}_{t+1}^{-1} \sum_{s=1}^t \mathbf{x}_{I_s} r_s$$

– odhad  $\alpha$  (lineárna regresia)

**Algoritmus podporuje skúmanie „správnych“ dimenzií  
pomocou vhodnej regularizácie**

## Základní banditi:

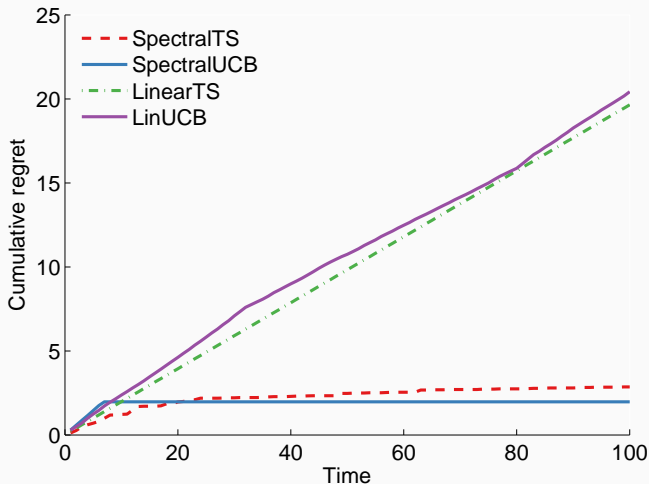
Názov algoritmu	Odhad na regret	Publikácia
LINUCB	$R_T = \tilde{O}(N\sqrt{T})$	Li et al., 2010
LINEARTS	$R_T = \tilde{O}(N\sqrt{T})$	Agrawal and Goyal, 2013
SUPLINREL	$R_T = \tilde{O}(\sqrt{NT})$	Auer, 2002

## Spektrálni banditi:

Názov algoritmu	Odhad na regret	Publikácia
SPECTRALUCB	$R_T = \tilde{O}(d\sqrt{T})$	Valko et al., 2014
SPECTRALTS	$R_T = \tilde{O}(d\sqrt{T})$	Kocak et al., 2014
SPECTRALELIMINATOR	$R_T = \tilde{O}(\sqrt{dT})$	Valko et al., 2014

# Empirické výsledky algoritmov



Flixster dataset:  $N = 972$ ,  $d < 10$



**Note:** SUPLINREL and SPECTRALELIMINATOR are not practical.



# Empirické výsledky algoritmov



## Spectral bandits

- **Nový setting** pre problémy s hladkými funkciami na grafe
- **Effective dimension** popisujúca komplexitu problému
- **Algoritmy** využívajúce hladkosť funkcie
  - Lepšie teoretické výsledky
  - Lepšie empirické výsledky

## References

**Tomáš Kocák**, Michal Valko, Rémi Munos, Shipra Agrawal: *Spectral Thompson Sampling*, The 28th AAAI Conference on Artificial Intelligence (AAAI 2014)

Michal Valko, Rémi Munos, Branislav Kveton, **Tomáš Kocák**: *Spectral Bandits for Smooth Graph Functions*, The 31th International Conference on Machine Learning (ICML 2014)

**Tomáš Kocák**, Michal Valko, Rémi Munos, Branislav Kveton, Shipra Agrawal: *Spectral Bandits*, to appear in Journal of Machine Learning Research (JMLR 2018)

**Ďakujem za pozornosť!**

**Čas na otázky...**