

# Neurónové siete a geomagnetické búrky

Gabriela Andrejková

Ústav informatiky  
Prírodovedecká fakulta UPJŠ v Košiciach



## Úvodné poznámky

Lundstedt, H., Wintoft, P.: *Prediction of Geomagnetic Storms from Solar Wind Data with the use of a Neural Network*. Am. Geophysicae 12, 19-24 (1994), EGS-Springer-Verlag.

prof. RNDr. Karel Kudela, DrSc., SAV - kozmické žiarenie

Modely rekurentných neurónových sietí (NS), ktoré boli použité pri predikcii geomagnetických búrok.

Pomocou fuzzy logiky hľadanie možností kombinácie NS s fuzzy informáciou.

Genetické algoritmy umožňujú hľadať lepšie topológie sietí. Ukážeme jednu z možností.


## Obsah prednášky

1. Motivácia
2. Predikcia geomagnetických búrok (GMS)
3. Dáta o GMS
4. Rekurentné NS pri predikcii GMS
5. Fuzzy NS pri predikcii GMS
6. Optimálny model NS pomocou genetických algoritmov

## Zem sa dostala pod paľbu slnečných erupcií


*Miroslav Vajs, 16.08.2011 11:20*

Slnko sa po šiestich relatívne pokojných rokoch opäť preberá k zvýšenej aktivite. Cez slnečné erupcie posiela nielen na Zem silné elektromagnetické žiarenie. Slnko sa opäť dostáva do aktívnej fázy, keď erupcie môžu vážne ohroziť funkčnosť satelitov, GPS i elektrickú prenosovú sústavu.



## Vrchol nového slnečného cyklu

Vraví sa o jedenásťročnom cykle, ale to je len jeho priemerná hodnota a v skutočnosti Slnko nedodrížiava presný grafikon, občas si ho aj o vyše roka skrúti, či predĺži.



*https :*

*//www.info.sk/sprava/134931/dnes – bude – mozne – pozorovat – polarnu – ziaru/*

6. 9. 2017: V oblasti slnečnej škvrny AR 2673 bol pred chvíľou pozorovaný silný lúč triedy X, informuje *imeteo.sk*. Lúč pochádza zo silnej slnečnej erupcie a počas dnešnej noci ovplyvní aj Zem. GMS vyvolá v oblasti magnetických pólov Zeme intenzívnu polárnu žiaru, ktorá bude pozorovateľná aj z miernych zemepisných šírok. Bude ju možné pozorovať až z oblasti Balkánu, Talianska či severného Španielska. Pozorovanie však môže prekaziť mnoho oblačnosti. Najlepšie podmienky by mali byť medzi 23:00 a 3:00 hod. nasledujúceho rána. Najmenej oblačnosti by v tomto čase malo byť v južnej oblasti stredného Slovenska.

13. 3. 2018:

*https : //refresher.sk/52598 – K – Zemi – sa – ruti – slnecna – burka – Do – doby – kamennej – nas – sice – neposle – no – moze – narusit – technologie*

## Čo to je geomagnetická búrka (GMB)

- magnetické pole Zeme - pole veľmi veľkého trvalého magnetu,
- kvantitatívny popis
  - fyzikálna veličina - **magnetická indukcia  $B$** , okolo  $0,5 \cdot 10^{-4} \text{T}$
  - fyzikálna veličina - **intenzita magnetického poľa  $H$** , približne  $24 \text{A.m}^{-1}$
- sila a smer magnetického poľa Zeme sa mení
- dochádza k výkyvom, ktoré trvajú niekoľko hodín alebo dní - **geomagnetické búrky (GMB)**

## Prečo vznikajú GMB

- procesy prebiehajúce na Slnku
- slnečné erupcie spôsobujú výrony častíc a žiarenia do medziplanetárneho priestoru
- **slnečný vietor** - prúd týchto častíc slnečného pôvodu, ktoré letia medziplanetárnym priestorom veľkou rýchlosťou (zo Slnka unikajú rýchlosťou 1000 až 3000 km/s)



## Čo môžu spôsobiť GMB

- aj keď pojem geomagnetická búrka znie dramaticky, pre človeka nie je nebezpečná
- ohrozené sú veľmi dlhé vodivé potrubia a elektrické vedenia najmä v smere poludníkov; meniace sa pole v nich naindukuje napätie, ktoré by mohlo poškodiť zariadenia rozvodných sietí, napríklad transformátory
- oblaky vysokoenergetických nabitých častíc však môžu spôsobiť vážne problémy tam, kde priestor už nie je pod ochranou štítu geomagnetického poľa - na družiciach, vesmírnych sondách, staniciach aj astronautom

## Carrington Event 1859

- pozorovaná gigantická explózia, ktorá vyvrhla smerom k Zemi obrovský mrak elektricky nabitej plazmy
- ten sa stretol v roku 1859 s magnetosférou
- polárne žiare sa rozžiarili od pólov až k trópom,
- telegrafické spojenia dostávali rany a zlyhávali

## Slnečná búrka, 1989

- omnoho slabšia ako 1859
- ale civilizácia existovala už s podstatne zložitejšou energetickou infraštruktúrou
- Quebec - blackout 8 hodín
- celkové škody dosiahli 10 mil. dolárov

[http : //omniweb.gsfc.nasa.gov/html/ow\\_data.html](http://omniweb.gsfc.nasa.gov/html/ow_data.html)

Oficiálna stránka, kde je možné získať dáta:

The screenshot shows the OMNIWeb website from the Goddard Space Flight Center. The header includes the NASA logo, the text 'GODDARD SPACE FLIGHT CENTER Space Physics Data Facility', and a search bar with the text 'SEARCH NASA' and a '+ 60' button. Below the header is a navigation bar with links: '+ HOME', '+ DATA & ORBITS', '+ ModelWeb at CCMC', '+ SCIENCE ENABLED', and '+ AND MORE'. The main content area features the 'OMNIWeb' logo and the text 'SPDF • Goddard Space Flight Center'. A sidebar on the left contains links: '+ OMNIWeb Plus Home', '+ OMNIWeb Home', '- ABOUT OMNI DATA', '+ FTP', '+ INPUT DATA', and '+ NEWS'. The main content area has a section titled 'OMNIWeb Data Documentation' and a 'Contents' list with 14 items: 1: Introduction, 2: Data availability, 3: Description of records and words, 4: Daily and 27-day Averages, 5: Spacecraft identifiers, 6: Activity Indices, 7: Energetic Particles fluxes, 8: Spacecraft prioritization for OMNI2 inclusion, 9: Data sources - IMF, 10: Data sources - Plasma, 11: Data cleaning, 12: Time-shifting of data, 13: Data set intercomparisons and parameter normalizations (with sub-items 13.1: Magnetic field comparisons and 13.2: Plasma comparisons), and 14: Acknowledgements.

## Predikcia pomocou modelových funkcií

Majme časovú postupnosť  $\mathbf{x} = (x(1), \dots, x(T))$ , pre ktorú platí

$$x(t) = f(x(t-1), \dots, x(t-p), p \geq 1),$$

hodnota v aktuálnom čase  $t$  závisí od predošlých členov postupnosti.

**Predikciu** rozumieme predpovedanie ďalšieho priebehu časovej postupnosti na základe jej predošlých hodnôt.

$$x(t+k) = f(x(t-1), \dots, x(t-p), p \geq 1, 0 \leq k \leq p)$$

Parameter  $k$  je **stupeň predikcie** a vyjadruje, ktorý člen postupnosti budeme predikovať v závislosti od predchádzajúcich  $p$  hodnôt.

## Predikcia pomocou modelových funkcií

V prípade  $k = 0$ , predikujeme hodnotu v čase  $t$ .

- na vstup modelu prezentujeme hodnoty  $x(t-1), \dots, x(t-p)$  a
- model vypočíta výstup

$$y(t) = G(x(t-1), \dots, x(t-p))$$

kde  $G$  je aproximácia funkcie  $f$ , ktorú počíta príslušný model, a  $y(t)$  je predikcia aktuálnej hodnoty, teda

$$y(t) = \hat{x}(t)$$

- výstup modelu  $y(t) = \hat{x}(t)$  je porovnaný s aktuálnou hodnotou  $x(t)$ , ktorá predstavuje očakávaný výstup
- podľa chyby predikcie sa model adaptuje tak, aby rozdiel medzi predikovanou a skutočnou hodnotou bol čo najmenší.

## Predikcia pomocou modelových funkcií

Dôležité pri tom je, aby

- model bol schopný rozpoznať zákonitosti, ktorými sa riadi priebeh danej časovej postupnosti, a
- aby ich vedel zovšeobecniť aj na iné postupnosti rovnakého typu, ktoré nepatria do množiny tréningových vzoriek.

Predikcia pomocou neurónových sietí nachádza v súčasnosti uplatnenie v mnohých oblastiach.

# Prečo sú neurónové siete použiteľné

Východisko Kolmogorov, 1957

Theorem (Kurková, 1991)

*Nech  $n \geq 2$  je prirodzené číslo,  $\sigma : R \rightarrow [0, 1]$  je sigmoidálna funkcia,  $f : [0, 1]^n \rightarrow R$  je spojitá funkcia a  $\varepsilon$  je kladné reálne číslo. Potom existuje prirodzené číslo  $k$  a schodovité funkcie typu  $\sigma$   $\psi^{p,i}, \phi^i, i = 1 \dots, k, p = 1, \dots, n$  také, že pre každé  $(x_1, \dots, x_n) \in [0, 1]^n$  platí*

$$|f(x_1, \dots, x_n) - \sum_{i=1}^k \phi^i \left( \sum_{p=1}^n \psi^{p,i}(x_p) \right)| < \varepsilon. \quad (1)$$



## Funkcionálne závislosti pri skúmaní GMB


Na sledovanie zmien magnetického poľa Zeme používame veličinu  $D_{st}$  nazývanú **indexom geomagnetického poľa Zeme**. V období klľudu:  $\pm 20\text{nT}$ . Počas GMS však môže klesnúť až o niekoľko sto nT počas niekoľkých hodín.

Priebeh GMS má tri fázy:

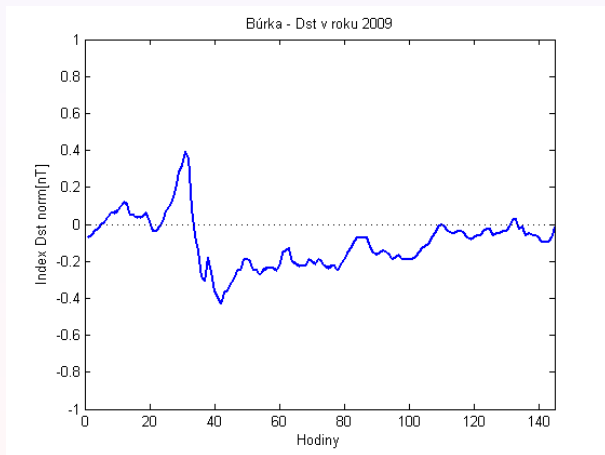
- počiatočnú fázu - mierne zvýšenie hodnoty  $D_{st}$
- hlavnú fázu - prudké zníženie hodnoty  $D_{st}$
- fázu obnovy - počas ktorej sa  $D_{st}$  postupne dostáva na pôvodnú úroveň

Jednotlivé fázy môžu mať pritom pre rôzne magnetické búrky rozdielnu dĺžku.

## Priebeh indexu *Dst* v roku 2009



## Priebeh indexu *Dst* jednej geomagnetickej búrky v roku 2009



## Funkcionálne závislosti pri skúmaní GMB

Index  $D_{st}$  fyzici sledujú v závislosti od veličín:

- $B_z$  - z-ová zložka vektora intenzity medziplanetárneho magnetického poľa, ktorá nadobúda hodnoty v intervale  $\pm 50 nT$ ,
- $\sigma_{B_z}$  - stredná kvadratická odchýlka  $B_z$ , ktorá charakterizuje výkyvy tejto veličiny,
- $n$  - počet častíc slnečného vetra v  $1 \text{ cm}^3$ ,
- $v$  - rýchlosť častíc slnečného vetra, ktorá dosahuje až  $1200 \text{ km/s}$ .

Budeme pomocou neurónovej siete predpovedať hodnoty indexu  $D_{st}$  v závislosti od týchto veličín.

## Úprava a výber dát

- 1996 prvé výsledky
- Dáta použité na predikciu boli vybrané z meraní, ktoré sa uskutočnili v rokoch 1963 - 1988, pričom každú hodinu boli namerané a zaznamenané hodnoty  $B_z$ ,  $\sigma_{B_z}$ ,  $n$ ,  $v$  a  $D_{st}$ .
- Keďže vo viacerých prípadoch sa počas určitého časového intervalu merania niektoré z veličín neuskutočnili, nahradili sme chýbajúce hodnoty interpoláciami v prípade, že časový interval, v ktorom bolo meranie veličiny prerušené, nepresahoval 24 hod.

2009	1	0	4.4	-0.2	0.3	0.8	2.5	-8
2009	1	1	4.0	-1.1	-1.0	0.7	2.5	-6
2009	1	2	4.8	-1.0	-0.5	0.9	2.1	-5
2009	1	3	4.9	-1.6	-1.2	0.8	2.1	-6
2009	1	4	4.1	-1.6	-1.6	0.9	2.5	-8
2009	1	5	3.5	-1.4	-1.5	1.7	2.6	-7
2009	1	6	4.3	-3.5	-3.5	0.7	2.4	-8
2009	1	7	4.5	-0.5	-0.5	2.4	2.2	-12
2009	1	8	4.7	-3.2	-3.3	1.4	2.3	-10
2009	1	9	4.9	-3.2	-3.1	0.9	2.5	-7
2009	1	10	4.2	-1.4	-1.3	1.1	2.6	-8
2009	1	11	5.0	-1.9	-2.2	1.4	2.6	-11
2009	1	12	4.9	-2.3	-2.5	0.7	2.6	-16
2009	1	13	4.8	0.0	-0.2	1.8	2.4	-19
2009	1	14	5.4	-0.4	-0.5	0.7	2.3	-16
2009	1	15	5.2	-0.8	-0.7	0.8	2.4	-14
2009	1	16	4.5	-1.7	-1.5	0.9	2.0	-14
2009	1	17	4.0	0.6	0.4	1.1	2.2	-16
2009	1	18	3.8	-0.4	-0.2	1.2	1.9	-17
2009	1	19	3.9	-1.1	-0.6	1.1	2.1	-16
2009	1	20	3.8	-1.2	-0.9	0.6	1.9	-15
2009	1	21	4.0	-1.5	-1.6	0.4	1.8	-13
2009	1	22	4.2	-0.5	-1.0	0.4	1.9	-8
2009	1	23	4.5	0.4	-0.4	0.2	2.0	-6
2009	2	0	5.1	1.1	0.2	0.4	1.6	-6
2009	2	1	5.2	0.7	0.4	0.3	1.6	-6
2009	2	2	4.4	-0.8	-0.8	0.8	1.8	-8
2009	2	3	3.4	-1.1	-0.8	0.9	2.7	-6

Takto upravené dáta sme potom použili na výber vzoriek do tréningovej množiny podľa nasledujúcich kritérií:

- ak hodnota  $D_{st}$  poklesla počas dvoch hodín najmenej o 40nT, tréningovú vzorku (búrku) sme vytvorili z meraní 36 hodín pred týmto poklesom, 2 hodiny poklesu, počas ktorých sme búrku identifikovali, a 108 hodín po poklese.  $36+2+108=144$ , 6 dní.

Súbor meraní pritom musel spĺňať podmienku, že počas týchto 145 hodín sa nevyskytli žiadne chýbajúce merania. Takto sme získali tréningovú vzorku.

Kompletné dáta sme potom normovali. Maximálne a minimálne hodnoty počas 26 rokov ukazuje tabuľka


veličina	maximum	minimum
$B_z$	-40,03	36,14
$\sigma_{Bz}$	0	103,20
$n$	0	139,00
$v$	0	1021,10
$D_{st}$	-387	70

Na základe toho sme zvolili normalizačné konštanty:

$max - B_z = 50$ ,  $max - \sigma_{B_z} = 120$ ,  $max - n = 150$ ,  $max - v = 1100$  a  $max - Dst = 400$ , pomocou ktorých sme v programe upravovali merania jednotlivých veličín na hodnoty z intervalu  $(-1, 1)$ , ktoré vyžadujú všetky použité typy sietí.



## Príklad neurónovej siete a chybovej siete



## Prvé modely

Diplomová práca, Azorová, 1996

Na úlohu predikcie hodnôt indexu  $D_{st}$  sme použili 4 typy sietí - jednu feed-forward sieť A a 3 rôzne čiastočne rekurentné siete C-D.

Vo všetkých prípadoch sieť dostávala na vstup namerané hodnoty  $B_z, \sigma_{B_z}, n, v$  upravené do intervalu  $\langle -1, 1 \rangle$  a jej úlohou bolo predpovedať hodnotu  $D_{st}$  jednu hodinu dopredu.

Prahový neurón s aktivačnou hodnotou trvale nastavenou na -1, z ktorého vedú prepojenia do všetkých neurónov vyššej vrstvy a váhy predstavujú prahy.

## Model A:




Figure: Model A použitý na predikciu

## Model A:

- Výstupná vrstva - 1 neurón, výstupom ktorého je predpovedaná hodnota indexu  $D_{st}$ .
- Skrytá vrstva obsahuje 26 neurónov
- Vstupná vrstva - 33 neurónov, to znamená 8 neurónov pre každú vstupnú veličinu a jeden prahový neurón.
- Na tréning siete sme použili metódu posúvania signálu pozdĺž vstupu, v tomto prípade sieť na základe hodnôt vstupných veličín za posledných 8 hodín predpovedá  $D_{st}$  v čase  $t + 1$ .

Tento typ sme zaradili pre porovnanie výsledkov práce feed-forward sietí a sietí s rekurentnými prepojeniami.

## Model B:




Figure: Model B použitý na predikciu

## Model B:

Má architektúru ako model A, doplnenú o 8 neurónov vo vstupnej vrstve, ktoré prijímajú výstupy siete spätným prepojením, ktoré je pevne nastavené na hodnotu 1.

Výstupné hodnoty sa postupne posúvajú pozdĺž tejto skupiny neurónov rovnako ako vstupné veličiny. Sieť tak má možnosť rozpoznať aj prípadnú závislosť aktuálnej hodnoty  $D_{st}$  na svojich vlastných predošlých hodnotách.

Učiaci algoritmus je podobný algoritmu A, na konci každého časového kroku sa však navyše výstupná hodnota uchová v poslednom z týchto 8 neurónov a ostatné ich hodnoty sa posunú o jedno miesto doľava.

## Model C:




Figure: Model C použitý na predikciu

## Model C:

Je čiastočne rekurentná sieť s kontextovými neurónmi, do ktorých vedú spätné prepojenia zo skrytej vrstvy. Prepojenia majú opäť pevné váhy 1. Množinou týchto kontextových neurónov doplníme sieť totožnú s modelom A. Kontextová množina teda pozostáva z 26 neurónov, každý z nich uchováva hodnotu príslušného neurónu skrytej vrstvy, ktorá je potom použitá v nasledujúcom časovom kroku.

Učiaci algoritmus sme vytvorili kombináciou metódy posúvania signálu a algoritmu pre siete s kontextovými neurónmi. Algoritmus A sme doplnili o ďalší krok nasledujúci po adaptácii, v ktorom priradíme kontextovým neurónom hodnoty neurónov skrytej vrstvy.



## Model D:




Figure: Model D použitý na predikciu

## Model D:

Vznikne z modelu C pridaním ďalšej množiny kontextových neurónov, do ktorých vedú prepojenia z výstupnej vrstvy.

V našom prípade je to vlastne jediný neurón uchovávajúci hodnotu  $D_{st}$  predpovedanú v predošlom časovom kroku. Výstupná hodnota sa v tomto neuróne uchová opäť až na konci práce v danom časovom kroku po adaptácii váh. Táto sieť tak uchováva predošlé stavy všetkých neurónov skrytej aj výstupnej vrstvy.

Algoritmus je totožný s prípadom C, do pridaného kontextového neurónu navyše uložíme výstupnú hodnotu.

## Vyhodnotenie

Na vyhodnotenie výsledkov modelov A - D sme použili dáta z iných rokov. Tieto boli vybrané jednak preto, že sa vyznačujú zvýšenou aktivitou geomagnetického poľa, ďalším dôvodom bolo to, že prakticky neobsahujú chýbajúce merania, ktoré sťažujú predikciu.

Koľko búrok bude predikovaných?

Na vstup každej zo 4 sietí s výslednými váhami, ktoré sú výsledkom procesu učenia, sme postupne predkladali hodnoty meraní daného roku.

Tieto výsledky sme potom vyhodnocovali podľa dvoch kritérií:

- **Stredná kvadratická odchýlka**

je mierou odlišnosti skutočných hodnôt od predikovaných sieťou.  
Počítame ju podľa vzťahu

$$s = \sqrt{\frac{1}{T} \sum_{t=1}^T (d(t) - y(t))^2}$$

pričom  $T$  je celkový počet hodín v danom roku ( $T=8760$  alebo  $T=8784$ ),  $d(t)$  je skutočne nameraná a  $y(t)$  predpovedaná hodnota indexu  $D_{st}$  v čase, ktorý zodpovedá meraniu  $t$  v danom roku.

- **Počet predikovaných poklesov  $D_{st}$ .**

Keďže magnetickú búrku identifikujeme prostredníctvom poklesu hodnoty  $D_{st}$  minimálne o  $40nT$  v priebehu dvoch hodín, porovnaním skutočného a predikovaného množstva takýchto poklesov v danom roku získame ďalšie meradlo úspešnosti siete pri predikcii magnetických búrok.

Za správne identifikovaný považujeme pritom pokles skutočných hodnôt  $D_{st}$  v prípade, ak mu zodpovedá pokles predikovaných hodnôt minimálne o  $40nT$  v časovom rozmedzí  $\pm 3$  hodiny od skutočného poklesu.

# Výsledky

model	1979			1980			1981		
	b=28			b=18			b=51		
	s	p	$u=p/b$	s	p	$u=p/b$	s	p	$u=p/b$
A	27,10	10	0,357	23,32	5	0,277	31,47	31	0,607
B	21,18	9	0,321	22,29	5	0,277	30,41	30	0,587
C	22,38	12	0,428	18,47	5	0,277	25,92	31	0,607
D	26,89	14	0,500	24,65	13	0,722	28,60	38	0,745

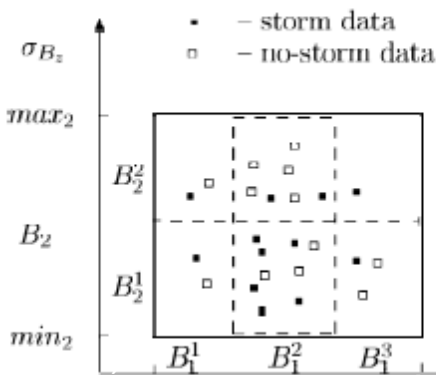
s - stredná kvadratická odchýlka, b - počet reálnych poklesov Dst, p - počet predikovaných poklesov Dst, p/b - úspešnosť predikcie

# Neuro-fuzzy klasifikátor (NFC)

Diplomová práca, H. Tóth, 1997

$$B_1 = \langle \min_1, \max_1 \rangle = \langle 174, 55030 \rangle$$

$$B_2 = \langle \min_2, \max_2 \rangle = \langle 0.01, 15.68 \rangle$$



## Neuro-fuzzy klasifikátor (NFC)

Nauck a Kruse, 1997, NFC je fuzzy systém

- trénovaný učiacim algoritmom (NS), môže byť popísaný ako dopredná NS, výpočtové jednotky používajú  $t - normu$  a  $t - conormu$  ako aktivačnú funkciu
- používa systém fuzzy pravidiel tvaru

**IF**  $x$  is  $B$  **AND**  $y$  is  $C$  **THEN**  $z$  is  $D$


$x, y, z$  sú premenné,  $B, C, D$  sú fuzzy množiny hodnôt lingvistických premenných,

- aproximuje (klasifikuje) hodnoty  $n$ -dimenzionálnej funkcie, ktorá je daná tréningovými dátami



## Príklad

$\mathcal{R}^1$  : IF  $x_1$  is  $B_1^1$  AND  $x_2$  is  $B_1^2$  THEN  $z$  is  $w^1$ ,  
 $\mathcal{R}^2$  : IF  $x_1$  is  $B_2^1$  AND  $x_2$  is  $B_1^2$  THEN  $z$  is  $w^2$ ,  
 $\mathcal{R}^3$  : IF  $x_1$  is  $B_3^1$  AND  $x_2$  is  $B_2^2$  THEN  $z$  is  $w^3$ .



## Vyhodnotenie

- Chyba prvého druhu  $E_1 = 1 - \frac{S}{B}$ ,  
neúspešnosť siete pri predpovedaní búrok, ktoré nastali.
- Chyba druhého druhu

$$E_2 = \frac{M}{n}.$$

vyjadruje, v akej časti príkladov ( $n$ ) sieť predpovedala búрку, aj keď táto v skutočnosti nenastala.

Učiaci algoritmus bol zameraný na minimalizáciu tejto chyby.

$B$  ... skutočný počet GM búrok v príslušnej vzorke,

$S$  ... počet búrok správne predpovedaných sieťou,

$M$  ... počet búrok, ktorých výskyt sieť predpovedala, aj keď tieto v skutočnosti nenastali

# Testovanie

Tri testovacie vzorky príkladov:

- Vzorka A obsahovala 9975 príkladov vytvorených z rokov 1982-1984.
- Vzorka B obsahovala 7674 príkladov vytvorených z rokov 1989, 1990 a 1992.
- Posledná, tretia, vzorka C obsahovala 17649 príkladov z oboch predchádzajúcich vzoriek.

Vzorka A obsahovala 32, vzorka B 94 a vzorka C 126 GM búrok presnejšie pásov príkladov, ktorých tretia zložka je 1).

# Výsledky

$\alpha$	$\beta$	$R$	Sample A ( $B = 37$ )		
			$S$	$1 - E_1$	$E_2$
0.30	20	136	29	78.38	2.78
0.25	20	145	29	78.38	2.41
0.45	20	116	24	64.86	2.28

$\alpha$	$\beta$	$R$	Sample B ( $B = 52$ )		
			$S$	$1 - E_1$	$E_2$
0.30	20	136	27	51.92	3.94
0.25	20	145	28	53.85	3.69
0.45	20	116	23	44.23	3.47

$\alpha$	$\beta$	$R$	Sample C ( $B = 89$ )		
			$S$	$1 - E_1$	$E_2$
0.30	20	136	56	62.92	3.18
0.25	20	145	57	64.04	2.85
0.45	20	116	47	52.81	2.68

$1 - E_1$  ... presnosť predikcie,  $E_2$  ... nesprávna predikcia

# Genetické algoritmy

## Kroky pri práci s populáciou NS

- Vygenerujeme inicializačnú populáciu sietí, pričom každú sieť reprezentuje jeden reťazec - je v ňom zakódovaná štruktúra siete.
- Každú sieť adaptujeme učiacim algoritmom backpropagation.
- Každdej sieti určíme jej fitness. Fitness funkciu definujeme ako kombináciu hodnôt kritérií na riešenie problému (napríklad rýchlosť adaptácie danej siete, jej presnosť, ale aj ďalšie faktory, ako sú veľkosť a zložitosť siete).
- Reťazce reprezentujúce jednotlivé siete prejdú procesom reprodukcie - reťazce jednej generácie plodia potomkov - reťazce novej generácie.

Diplomová práca, Marčišinová, 1997


Napríklad:

Ak  $E(i)$  je chyba  $i$ -tej siete a  $NC(i)$  je počet spojení tejto siete,  $k_1$ ,  $k_2$  sú zvolené koeficienty, tak  $f(i)$  ako vhodnosť  $i$ -tej siete

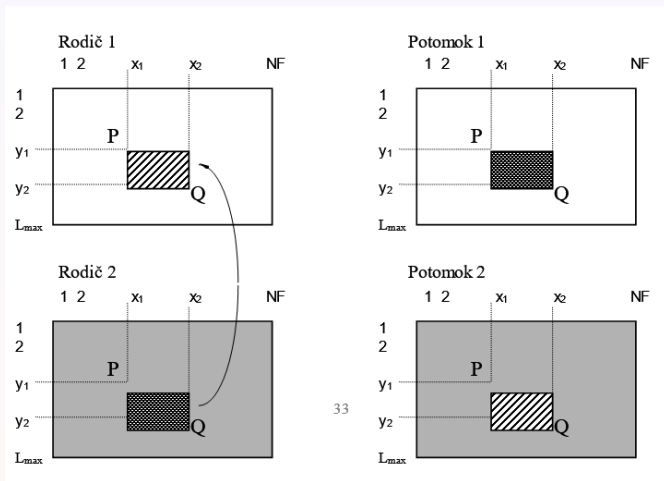
$$f(i) = k_1 * \frac{1}{E(i)} + k_2 * \frac{1}{NC(i)}$$

Snahou je modifikovať aj topológiu siete.

## Reprezentácia siete pomocou matice




## Aplikácia operácie kríženia



33



## Aplikácia operácie mutácie




# Výsledný priebeh jednej z búrok

k sieťou predikovaným hodnotám

## MODEL D\_E :

- sieť bola optimalizovaná 40 behmi GA a 120 behmi BP.




## Výsledky týchto modelov

Vzhľadom na výpočtové možnosti pracovali sme s malými populáciami sietí, s malým počtom aplikácií genetických operácií a úspešnosť predikcie bola malá - okolo 20%.

Zaujímali sme sa tu hlavne o možné modifikácie sietí, čo genetické algoritmy poskytujú.

## S práním krajšej budúcnosti...



Ďakujem za pozornosť